# Elementy odstające (*outliers*)

> **Kontekst ćwiczeń:** Pracujemy z danymi sprzedażowymi sklepu internetowego.
> Cel: zidentyfikować nietypowe obserwacje, zrozumieć ich przyczyny i podjąć decyzję — usunąć, skorygować czy zachować.

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy import stats

pd.set_option('display.max_rows', 40)
pd.set_option('display.float_format', '{:.2f}'.format)
plt.rcParams['figure.dpi'] = 100
plt.rcParams['font.size'] = 11

np.random.seed(42)
```

## Czym są elementy odstające?

**Element odstający (outlier)** to obserwacja, która znacząco odbiega od pozostałych danych. Może wynikać z:

- **błędu pomiaru / wpisu** — literówka, awaria czujnika, podwójne zaksięgowanie
- **rzeczywistego zdarzenia** — wyprzedaż Black Friday, awaria serwera, viralowy post
- **zmiany procesu** — nowa kampania reklamowa, zmiana cen, wejście na nowy rynek

### Dlaczego to ważne?

Outliersy mogą poważnie wpływać na analizę statystyczną i modele predykcyjne: średnia arytmetyczna, odchylenie standardowe, regresja liniowa — wszystko to jest wrażliwe na wartości ekstremalne. Jednocześnie outliersy mogą nieść **cenną informację biznesową**, więc nie zawsze należy je usuwać.

## Typy elementów odstających

| Typ | Opis | Przykład |
|---|---|---|
| **Jednowymiarowy** | Ekstremalna wartość jednej zmiennej | Sprzedaż 5× wyższa niż zwykle |
| **Wielowymiarowy** | Nietypowa kombinacja zmiennych (każda z osobna OK) | Klient 22-letni z dochodem 500 tys. zł |
| **Kontekstowy** | Wartość normalna w jednym kontekście, odstająca w innym | 200 sztuk w poniedziałek vs 200 sztuk w niedzielę |

# Metody wykrywania elementów odstających

| # | Metoda | Typ | Założenia |
|---|---|---|---|
| 1 | Wykres pudełkowy (Boxplot) | wizualna | brak |
| 2 | Metoda IQR | statystyczna, nieparametryczna | brak |
| 3 | Z-score | statystyczna, parametryczna | rozkład normalny |
| 4 | Zmodyfikowany Z-score (MAD) | statystyczna, odporna (robust) | brak |
| 5 | Percentyle | statystyczna, nieparametryczna | brak |

In [1]:

# Przykład

In [2]:
```
# Wynagrodzenia brutto (tys. zł) — 24 pracowników małej firmy IT
df = pd.DataFrame({
    'pracownik': [
        'Anna', 'Bartek', 'Celina', 'Dawid', 'Ewa',       # juniorzy
        'Filip', 'Gosia', 'Hubert', 'Iwona', 'Jakub',      # regularni
        'Kasia', 'Lena', 'Marcin', 'Natalia', 'Oskar',     # regularni
        'Patryk', 'Robert', 'Sylwia', 'Tomek', 'Urszula',  # seniorzy
        'Wiktor',                                            # kierownik działu
        'Zuzia',                                             # stażystka (pół et
        'Dyrektor',                                          # CEO
        'Gosia_2',                                           # ← błąd wpisu: 5.5
    ],
    'wynagrodzenie': [
        4.2, 4.5, 4.8, 5.0, 5.1,
        5.3, 5.5, 5.5, 5.8, 6.0,
        6.2, 6.3, 6.5, 6.8, 7.0,
        7.2, 7.5, 8.0, 8.5, 9.0,
        12.0,
        1.8,
        25.0,
        55.0,
    ]
})

wyn = df['wynagrodzenie']

print("DANE: wynagrodzenia pracowników (tys. zł)")
print("=" * 50)
print(df.to_string(index=False))
print(f"\nLiczba obserwacji: {len(df)}")

wyn = df['wynagrodzenie']
print(f"\nŚrednia:  {wyn.mean():.2f} tys. zł")
print(f"Mediana:  {wyn.median():.2f} tys. zł")
print(f"Std:      {wyn.std():.2f} tys. zł")
print(f"Min:      {wyn.min():.2f} tys. zł")
print(f"Max:      {wyn.max():.2f} tys. zł")
```

```
print(f"\n→ Średnia ({wyn.mean():.1f}) jest wyraźnie wyższa od mediany ({wyn.med
print("  — to już sygnał, że w danych mogą być outliersy górne!")
```

```
DANE: wynagrodzenia pracowników (tys. zł)
==================================================
pracownik  wynagrodzenie
     Anna           4.20
   Bartek           4.50
   Celina           4.80
    Dawid           5.00
      Ewa           5.10
    Filip           5.30
    Gosia           5.50
   Hubert           5.50
    Iwona           5.80
    Jakub           6.00
    Kasia           6.20
     Lena           6.30
   Marcin           6.50
  Natalia           6.80
    Oskar           7.00
   Patryk           7.20
   Robert           7.50
   Sylwia           8.00
    Tomek           8.50
  Urszula           9.00
   Wiktor          12.00
    Zuzia           1.80
 Dyrektor          25.00
  Gosia_2          55.00

Liczba obserwacji: 24

Średnia:  9.10 tys. zł
Mediana:  6.25 tys. zł
Std:      10.67 tys. zł
Min:      1.80 tys. zł
Max:      55.00 tys. zł

→ Średnia (9.1) jest wyraźnie wyższa od mediany (6.2)
  — to już sygnał, że w danych mogą być outliersy górne!
```

# Boxplot metoda

## Metoda 1: Wykres pudełkowy (Boxplot)

Boxplot wizualizuje rozkład danych przez kwartyle. Elementy poza „wąsami" (1.5 × IQR od krawędzi pudełka) traktowane są jako potencjalne outliersy.

Jest to jednocześnie **wizualizacja** i **metoda detekcji** — idealna na początek.

In [3]:
```
fig, ax = plt.subplots(figsize=(8, 4))
bp_vertical = ax.boxplot(df['wynagrodzenie'])
ax.set_xlabel('Wynagrodzenie (tys. zł)')
ax.set_title('Boxplot — wynagrodzenia pracowników')
ax.grid(True, alpha=0.3)
```

```
plt.tight_layout()
plt.show()
```

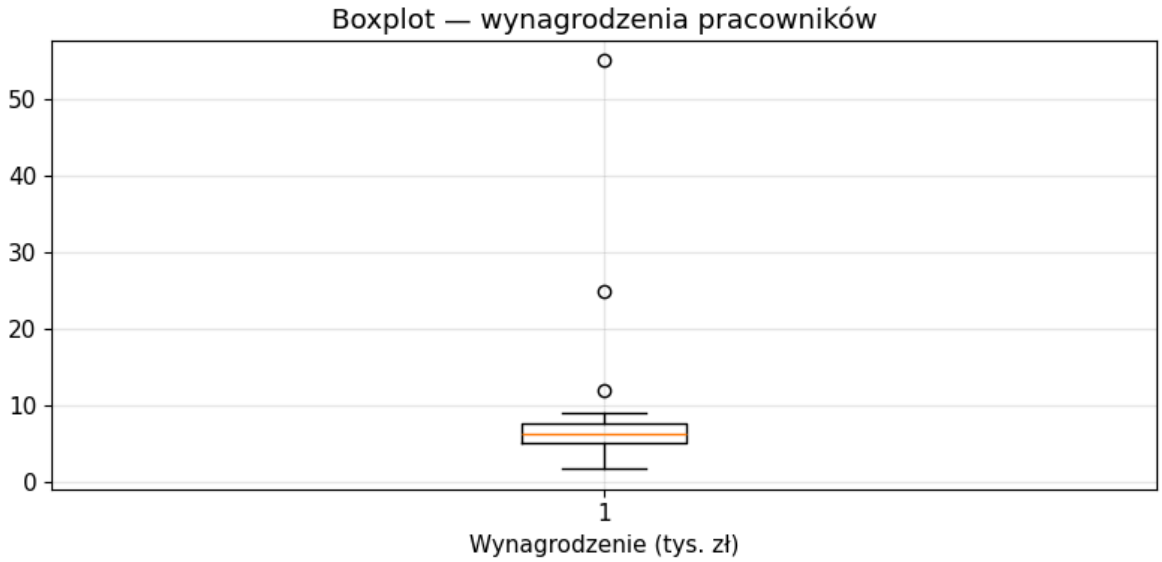


In [4]:
```
fig, ax = plt.subplots(figsize=(8, 4))
bp_horizontal = ax.boxplot(df['wynagrodzenie'], vert=False, patch_artist=True,
                boxprops=dict(facecolor='lightblue', edgecolor='navy'),
                flierprops=dict(marker='o', markerfacecolor='red', markersize=10
ax.set_xlabel('Wynagrodzenie (tys. zł)')
ax.set_title('Boxplot — wynagrodzenia pracowników')
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```

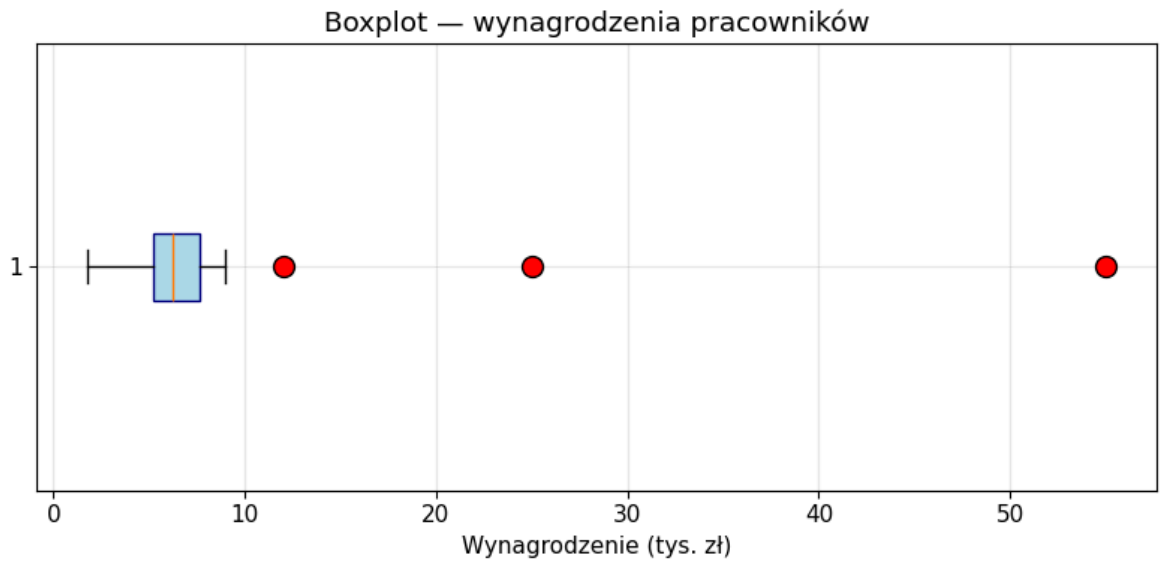


## Metoda 2: Rozstęp ćwiartkowy (IQR)

**Wzór:**

$$\text{IQR} = Q_3 - Q_1$$

**Granice:**

- dolna: $Q_1 - 1.5 \times \text{IQR}$
- górna: $Q_3 + 1.5 \times \text{IQR}$

Wartości poza granicami uznajemy za outliersy. Metoda **nieparametryczna** — nie wymaga rozkładu normalnego. To ta sama logika, którą stosuje boxplot.

In [5]:
```
wyn = df['wynagrodzenie']
Q1 = wyn.quantile(0.25)
Q3 = wyn.quantile(0.75)
IQR = Q3 - Q1
dolny_limit = Q1 - 1.5 * IQR
gorny_limit = Q3 + 1.5 * IQR

print("METODA IQR")
print("=" * 50)
print(f"Q1 = {Q1:.2f}")
print(f"Q3 = {Q3:.2f}")
print(f"IQR = {IQR:.2f}")
print(f"\nDolny limit = {Q1:.2f} - 1.5 × {IQR:.2f} = {dolny_limit:.2f}")
print(f"Górny limit = {Q3:.2f} + 1.5 × {IQR:.2f} = {gorny_limit:.2f}")

maska_iqr = (wyn < dolny_limit) | (wyn > gorny_limit)
print(f"\nWykryte outliersy ({maska_iqr.sum()}):")
print(df[maska_iqr][['pracownik', 'wynagrodzenie']].to_string(index=False))
```

```
METODA IQR
==================================================
Q1 = 5.25
Q3 = 7.62
IQR = 2.38

Dolny limit = 5.25 - 1.5 × 2.38 = 1.69
Górny limit = 7.62 + 1.5 × 2.38 = 11.19

Wykryte outliersy (3):
pracownik  wynagrodzenie
   Wiktor          12.00
 Dyrektor          25.00
  Gosia_2          55.00
```

## Metoda 3: Z-score (standaryzacja)

**Wzór:**

$$z_i = \frac{x_i - \bar{x}}{s}$$

Wartość $|z| > 3$ oznacza, że obserwacja leży ponad 3 odchylenia standardowe od średniej — w rozkładzie normalnym dotyczy to < 0.3% danych.

**Uwaga:** Średnia i odchylenie standardowe **same są wrażliwe na outliersy**, więc skrajne wartości „rozciągają" skalę i mogą maskować umiarkowane anomalie.

In [6]:
```
z_scores = np.abs(stats.zscore(wyn))
df['z_score'] = z_scores

print("METODA Z-SCORE")
print("=" * 50)
print(f"Średnia (x̄) = {wyn.mean():.2f}")
print(f"Odch. std (s) = {wyn.std():.2f}")
```

```
maska_z3 = z_scores > 3
maska_z2 = z_scores > 2

print(f"\nOutliersy (|z| > 3): {maska_z3.sum()}")
if maska_z3.sum() > 0:
    print(df[maska_z3][['pracownik', 'wynagrodzenie', 'z_score']].to_string(inde

print(f"\nPotencjalne outliersy (|z| > 2): {maska_z2.sum()}")
if maska_z2.sum() > 0:
    print(df[maska_z2][['pracownik', 'wynagrodzenie', 'z_score']].to_string(inde

print("\n→ Wartość 55.0 (Gosia_2) tak mocno zawyża std,")
print("  że np. Zuzia (1.8) czy Dyrektor (25.0) mogą nie wyjść jako outliersy!")
```

```
METODA Z-SCORE
==================================================
Średnia (x̄) = 9.10
Odch. std (s) = 10.67

Outliersy (|z| > 3): 1
pracownik  wynagrodzenie  z_score
  Gosia_2          55.00     4.39

Potencjalne outliersy (|z| > 2): 1
pracownik  wynagrodzenie  z_score
  Gosia_2          55.00     4.39

→ Wartość 55.0 (Gosia_2) tak mocno zawyża std,
  że np. Zuzia (1.8) czy Dyrektor (25.0) mogą nie wyjść jako outliersy!
```

## Metoda 4: Zmodyfikowany Z-score (MAD)

Klasyczny Z-score używa średniej i std, które same są wrażliwe na outliersy.

**Zmodyfikowany Z-score** zastępuje je odporniejszymi odpowiednikami:

$$\text{MAD} = \text{median}(|x_i - \tilde{x}|)$$

$$M_i = \frac{0.6745 \cdot (x_i - \tilde{x})}{\text{MAD}}$$

Próg: $|M_i| > 3.5$ (zalecenie Iglewicza i Hoaglina, 1993).

Kluczowa różnica: **mediana i MAD nie zmieniają się** pod wpływem jednej ekstremalnej wartości — dlatego metoda jest **odporna (robust)**.

In [7]:
```
mediana = wyn.median()
mad = np.median(np.abs(wyn - mediana))
modified_z = np.abs(0.6745 * (wyn - mediana) / mad)
df['mod_z_score'] = modified_z

print("METODA MAD (Zmodyfikowany Z-score)")
print("=" * 50)
print(f"Mediana = {mediana:.2f}")
print(f"MAD     = {mad:.2f}")

maska_mad = modified_z > 3.5
print(f"\nOutliersy (|M| > 3.5): {maska_mad.sum()}")
```

```
if maska_mad.sum() > 0:
    print(df[maska_mad][['pracownik', 'wynagrodzenie', 'mod_z_score']].to_string

print("\n→ MAD wykrywa więcej anomalii niż Z-score,")
print("  bo Gosia_2 (55.0) nie zaburza miar bazowych.")
```

```
METODA MAD (Zmodyfikowany Z-score)
==================================================
Mediana = 6.25
MAD     = 1.20

Outliersy (|M| > 3.5): 2
pracownik  wynagrodzenie  mod_z_score
 Dyrektor          25.00        10.54
  Gosia_2          55.00        27.40

→ MAD wykrywa więcej anomalii niż Z-score,
  bo Gosia_2 (55.0) nie zaburza miar bazowych.
```

## Metoda 5: Percentyle

Najprostsza metoda: odcinamy skrajne wartości na wybranym progu procentowym.

- **Rygorystycznie:** poniżej 1. i powyżej 99. percentyla
- **Łagodnie:** poniżej 5. i powyżej 95. percentyla

Metoda przydatna szczególnie przy **winzorowaniu** — zastępowaniu ekstremalnych wartości wartościami granicznymi.

In [8]:
```
print("METODA PERCENTYLI")
print("=" * 50)

for dolny_p, gorny_p in [(1, 99), (5, 95)]:
    p_low = wyn.quantile(dolny_p / 100)
    p_high = wyn.quantile(gorny_p / 100)
    maska = (wyn < p_low) | (wyn > p_high)

    print(f"\nPróg {dolny_p}-{gorny_p} percentyl:")
    print(f"  Dolna granica = {p_low:.2f}")
    print(f"  Górna granica = {p_high:.2f}")
    print(f"  Wykryte outliersy: {maska.sum()}")
    if maska.sum() > 0:
        print(df[maska][['pracownik', 'wynagrodzenie']].to_string(index=False))
```

```
METODA PERCENTYLI
==================================================

Próg 1-99 percentyl:
  Dolna granica = 2.35
  Górna granica = 48.10
  Wykryte outliersy: 2
pracownik  wynagrodzenie
    Zuzia           1.80
  Gosia_2          55.00

Próg 5-95 percentyl:
  Dolna granica = 4.25
  Górna granica = 23.05
  Wykryte outliersy: 4
pracownik  wynagrodzenie
     Anna           4.20
    Zuzia           1.80
 Dyrektor          25.00
  Gosia_2          55.00
```

## Outliersy wielowymiarowe

W praktyce anomalie często ujawniają się dopiero gdy spojrzymy na **kombinację zmiennych**. Każda zmienna z osobna może wyglądać normalnie, ale ich **połączenie** jest nietypowe.

In [9]:
```
# Dane: doświadczenie (lata) vs wynagrodzenie
df_2d = pd.DataFrame({
    'pracownik': ['Anna', 'Bartek', 'Celina', 'Dawid', 'Ewa',
                  'Filip', 'Gosia', 'Hubert', 'Iwona', 'Jakub',
                  'Kasia', 'Lena'],
    'doswiadczenie': [1, 2, 3, 5, 7, 8, 10, 12, 15, 3, 6, 20],
    'wynagrodzenie': [4.5, 5.0, 5.5, 6.5, 7.0, 7.5, 8.0, 9.0, 10.0, 12.0, 4.0, 8
})

print("DANE: doświadczenie vs wynagrodzenie")
print("=" * 45)
print(df_2d.to_string(index=False))

# Z-score per kolumna
z_dosw = np.abs(stats.zscore(df_2d['doswiadczenie']))
z_wyn = np.abs(stats.zscore(df_2d['wynagrodzenie']))
df_2d['outlier'] = (z_dosw > 2) | (z_wyn > 2)

print(f"\n→ Jakub: 3 lata doświadczenia, a zarabia 12.0 — protegowany?")
print(f"→ Kasia: 6 lat doświadczenia, a zarabia 4.0 — niedoceniana?")
print(f"→ Lena: 20 lat i tylko 8.0 — stagnacja?")
print(f"\n  Żadna z tych wartości nie jest ekstremalna SAMA W SOBIE,")
print(f"  ale ich KOMBINACJA jest podejrzana!")

# Scatter plot
fig, ax = plt.subplots(figsize=(8, 6))

normalne = df_2d[~df_2d['outlier']]
outl = df_2d[df_2d['outlier']]

ax.scatter(normalne['doswiadczenie'], normalne['wynagrodzenie'],
```

```
            s=80, color='steelblue', label='Normalne')

# Zaznacz interesujące przypadki ręcznie
for _, row in df_2d.iterrows():
    if row['pracownik'] in ['Jakub', 'Kasia', 'Lena']:
        ax.scatter(row['doswiadczenie'], row['wynagrodzenie'],
                   s=150, color='red', marker='X', zorder=5)
        ax.annotate(f"{row['pracownik']} ({row['doswiadczenie']}l, {row['wynagro
                    (row['doswiadczenie'], row['wynagrodzenie']),
                    textcoords="offset points", xytext=(10, 5), fontsize=9, colo

# Linia trendu
z = np.polyfit(df_2d['doswiadczenie'], df_2d['wynagrodzenie'], 1)
x_line = np.linspace(0, 22, 100)
ax.plot(x_line, np.polyval(z, x_line), 'g--', alpha=0.5, label='Trend liniowy')

ax.scatter([], [], s=150, color='red', marker='X', label='Podejrzane przypadki')
ax.set_xlabel('Doświadczenie (lata)')
ax.set_ylabel('Wynagrodzenie (tys. zł)')
ax.set_title('Outliersy wielowymiarowe — doświadczenie vs wynagrodzenie')
ax.legend()
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```

```
DANE: doświadczenie vs wynagrodzenie
============================================
pracownik  doswiadczenie  wynagrodzenie
     Anna              1           4.50
   Bartek              2           5.00
   Celina              3           5.50
    Dawid              5           6.50
      Ewa              7           7.00
    Filip              8           7.50
    Gosia             10           8.00
   Hubert             12           9.00
    Iwona             15          10.00
    Jakub              3          12.00
    Kasia              6           4.00
     Lena             20           8.00

→ Jakub: 3 lata doświadczenia, a zarabia 12.0 — protegowany?
→ Kasia: 6 lat doświadczenia, a zarabia 4.0 — niedoceniana?
→ Lena: 20 lat i tylko 8.0 — stagnacja?

  Żadna z tych wartości nie jest ekstremalna SAMA W SOBIE,
  ale ich KOMBINACJA jest podejrzana!
```

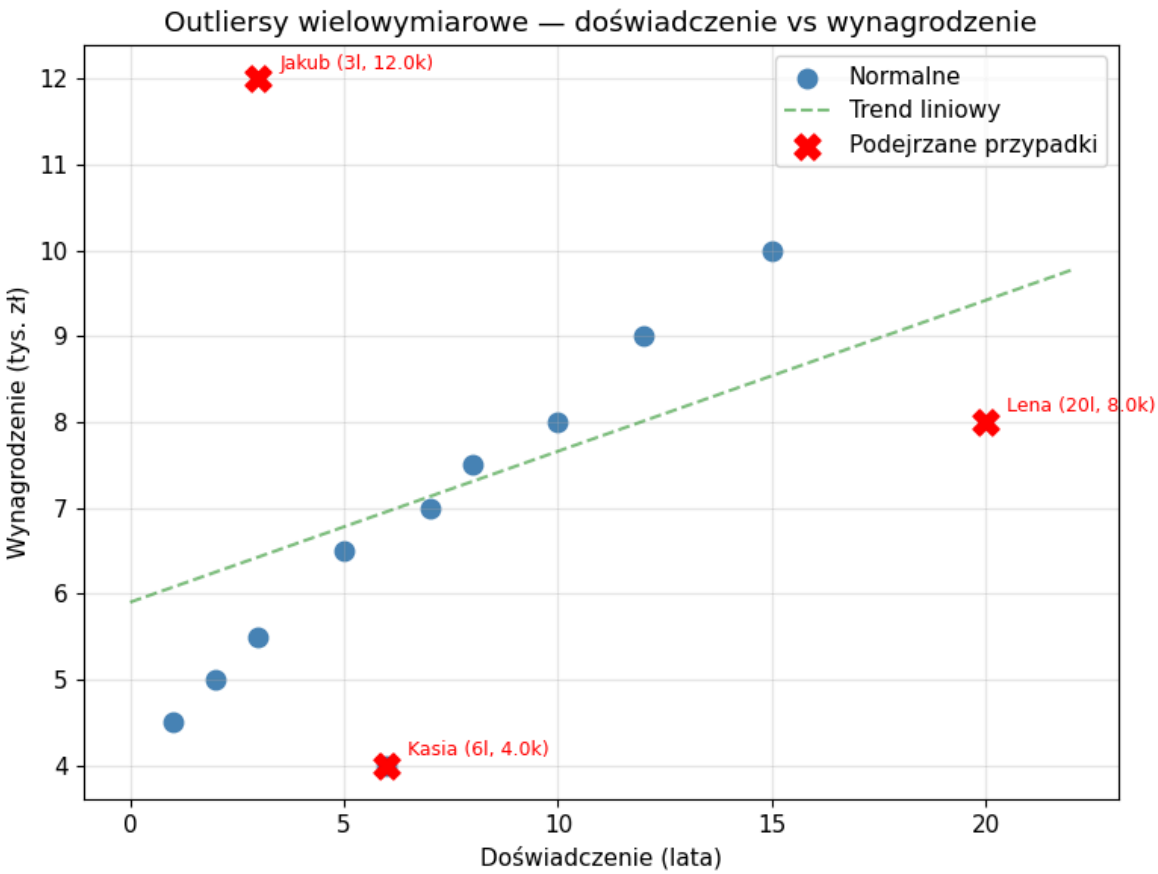


---

# Zadanie

Plik `sprzedaz_dzienna.csv` zawiera **90 dni** danych sprzedażowych sklepu internetowego z kolumnami: `sprzedaz`, `dzien_tygodnia`, `przychod`, `wizyty`, `zwroty`.

**Polecenia:**

1. Wczytaj dane i wyświetl podstawowe statystyki opisowe (wszystkie kolumny numeryczne).
2. Narysuj serię czasową sprzedaży oraz boxplot — ogólny i wg dnia tygodnia.
3. Zastosuj **trzy metody** wykrywania outlierów dla kolumny `sprzedaz`: IQR, Z-score, MAD. Porównaj wyniki.
4. Zbadaj **outliersy wielowymiarowe**: zrób scatter plot `wizyty` vs `sprzedaz` — czy widzisz nietypowe kombinacje?
5. Sprawdź kolumnę `zwroty` — czy widzisz dni z podejrzanie wysokim procentem zwrotów względem sprzedaży?
6. Dla każdego wykrytego outliera zaproponuj hipotezę: co mogło się stać?
7. Zaproponuj strategię postępowania z każdym outlierem (usunąć / skorygować / zachować / oznaczyć).

In [11]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

```
df = pd.read_csv('sprzedaz_dzienna.csv')
df['data'] = pd.to_datetime(df['data'])

print("--- ZADANIE 1: STATYSTYKI OPISOWE ---")
print(df.describe().to_string())
print("\n")

fig, axes = plt.subplots(3, 1, figsize=(12, 18))

sns.lineplot(data=df, x='data', y='sprzedaz', ax=axes[0])
axes[0].set_title('ZADANIE 2: Szereg czasowy sprzedaży')

sns.boxplot(data=df, x='sprzedaz', ax=axes[1])
axes[1].set_title('ZADANIE 2: Boxplot - ogólny dla sprzedaży')

kolejnosc_dni = ['Mon', 'Tue', 'Wed', 'Thu', 'Fri', 'Sat', 'Sun']
sns.boxplot(data=df, x='dzien_tygodnia', y='sprzedaz', order=kolejnosc_dni, ax=a
axes[2].set_title('ZADANIE 2: Boxplot sprzedaży wg dnia tygodnia')

plt.tight_layout()
plt.show()

print("--- ZADANIE 3: WYKRYWANIE OUTLIERÓW (IQR, Z-SCORE, MAD) ---")
Q1 = df['sprzedaz'].quantile(0.25)
Q3 = df['sprzedaz'].quantile(0.75)
IQR = Q3 - Q1
outliers_iqr = df[(df['sprzedaz'] < (Q1 - 1.5 * IQR)) | (df['sprzedaz'] > (Q3 +

mean_sprzedaz = df['sprzedaz'].mean()
std_sprzedaz = df['sprzedaz'].std()
df['z_score'] = (df['sprzedaz'] - mean_sprzedaz) / std_sprzedaz
outliers_z = df[df['z_score'].abs() > 3]

median_sprzedaz = df['sprzedaz'].median()
mad = np.median(np.abs(df['sprzedaz'] - median_sprzedaz))
df['mad_score'] = np.abs(df['sprzedaz'] - median_sprzedaz) / (mad * 1.4826)
outliers_mad = df[df['mad_score'] > 3]

print(f"Metoda IQR (liczba: {len(outliers_iqr)}):")
print(outliers_iqr[['data', 'sprzedaz']].to_string(index=False))
print(f"\nMetoda Z-score (liczba: {len(outliers_z)}):")
print(outliers_z[['data', 'sprzedaz', 'z_score']].to_string(index=False))
print(f"\nMetoda MAD (liczba: {len(outliers_mad)}):")
print(outliers_mad[['data', 'sprzedaz', 'mad_score']].to_string(index=False))
print("\n")

plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='wizyty', y='sprzedaz')
plt.title('ZADANIE 4: Outliery wielowymiarowe (Wizyty vs Sprzedaż)')
plt.show()

print("--- ZADANIE 5: ANALIZA ZWROTÓW ---")
df['procent_zwrotow'] = (df['zwroty'] / df['sprzedaz']) * 100
podejrzane_zwroty = df[df['procent_zwrotow'] > 12]
print("Dni z odsetkiem zwrotów powyżej 12%:")
print(podejrzane_zwroty[['data', 'sprzedaz', 'zwroty', 'procent_zwrotow']].to_st
```

```
--- ZADANIE 1: STATYSTYKI OPISOWE ---
       Unnamed: 0                 data  sprzedaz  przychod   wizyty  zwroty
count       90.00                   90     90.00     90.00    90.00   90.00
mean        44.50  2024-02-14 12:00:00    163.03   9109.68  5214.49    8.60
min          0.00  2024-01-01 00:00:00      8.00    442.06   410.00    1.00
25%         22.25  2024-01-23 06:00:00    144.75   7575.17  4432.25    6.00
50%         44.50  2024-02-14 12:00:00    163.00   8964.28  5066.00    8.00
75%         66.75  2024-03-07 18:00:00    176.75  10060.07  5887.00   11.00
max         89.00  2024-03-30 00:00:00    437.00  39900.00 14344.00   24.00
std         26.12                  NaN     53.75   4389.05  1723.74    4.18
```

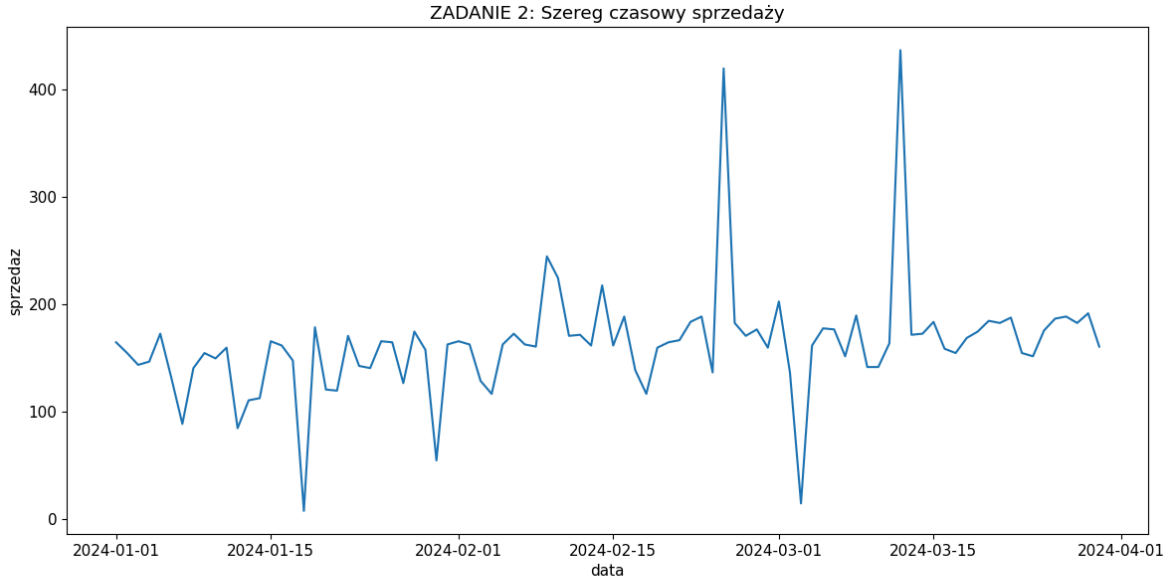
ZADANIE 2: Szereg czasowy sprzedaży
sprzedaz
0
100
200
300
400
2024-01-01
2024-01-15
2024-02-01
2024-02-15
2024-03-01
2024-03-15
2024-04-01
data

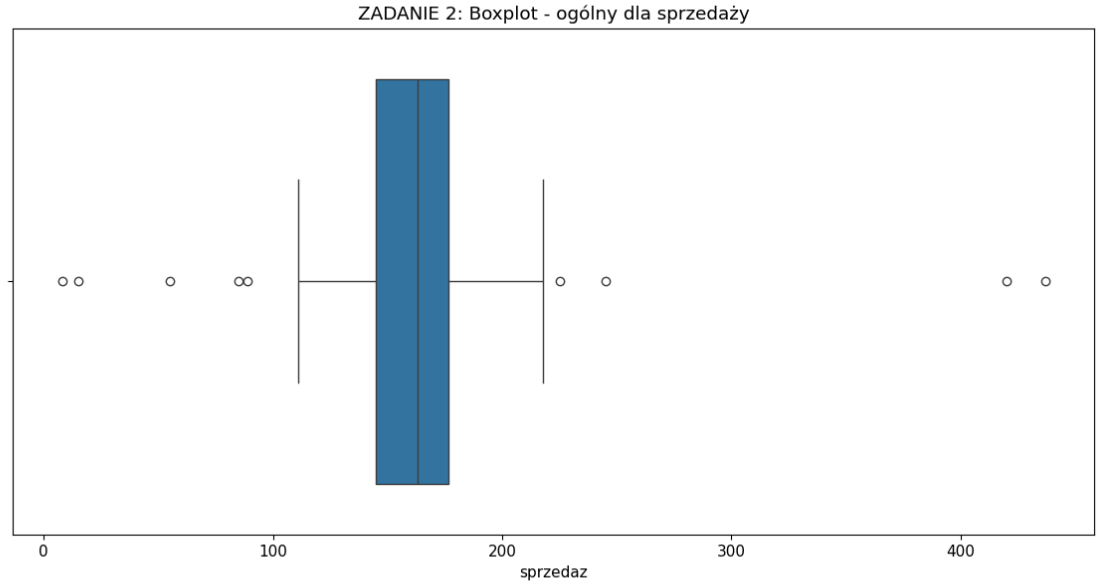
ZADANIE 2: Boxplot - ogólny dla sprzedaży
0
100
200
300
400
sprzedaz

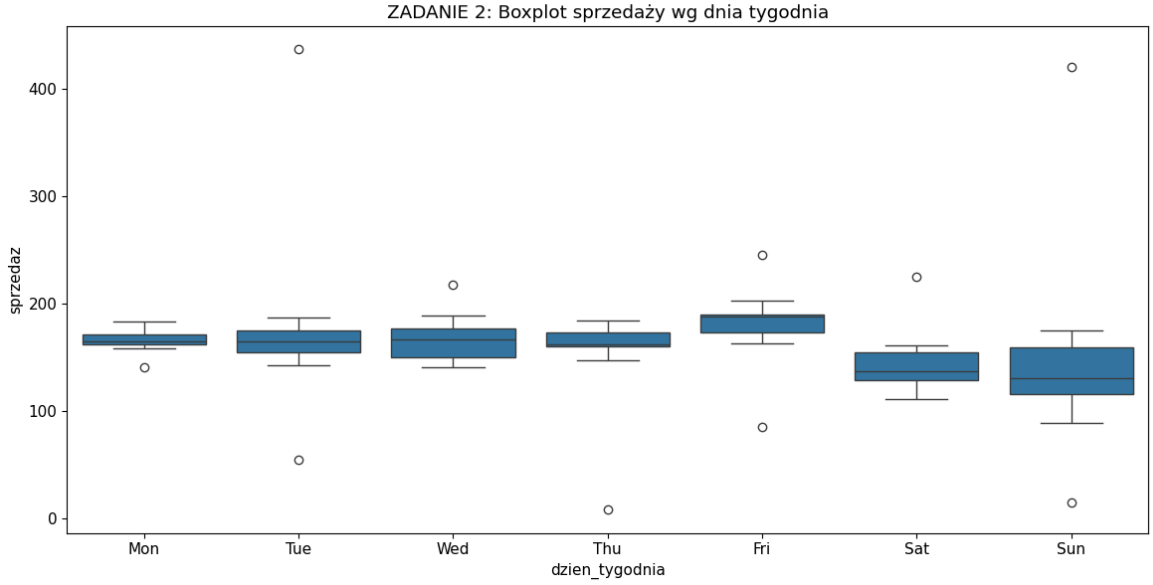
ZADANIE 2: Boxplot sprzedaży wg dnia tygodnia
sprzedaz
0
100
200
300
400
Mon
Tue
Wed
Thu
Fri
Sat
Sun
dzien_tygodnia

```
--- ZADANIE 3: WYKRYWANIE OUTLIERÓW (IQR, Z-SCORE, MAD) ---
Metoda IQR (liczba: 9):
      data  sprzedaz
2024-01-07        89
2024-01-12        85
2024-01-18         8
2024-01-30        55
2024-02-09       245
2024-02-10       225
2024-02-25       420
2024-03-03        15
2024-03-12       437

Metoda Z-score (liczba: 2):
      data  sprzedaz  z_score
2024-02-25       420     4.78
2024-03-12       437     5.10

Metoda MAD (liczba: 8):
      data  sprzedaz  mad_score
2024-01-07        89       3.33
2024-01-12        85       3.51
2024-01-18         8       6.97
2024-01-30        55       4.86
2024-02-09       245       3.69
2024-02-25       420      11.56
2024-03-03        15       6.65
2024-03-12       437      12.32
```

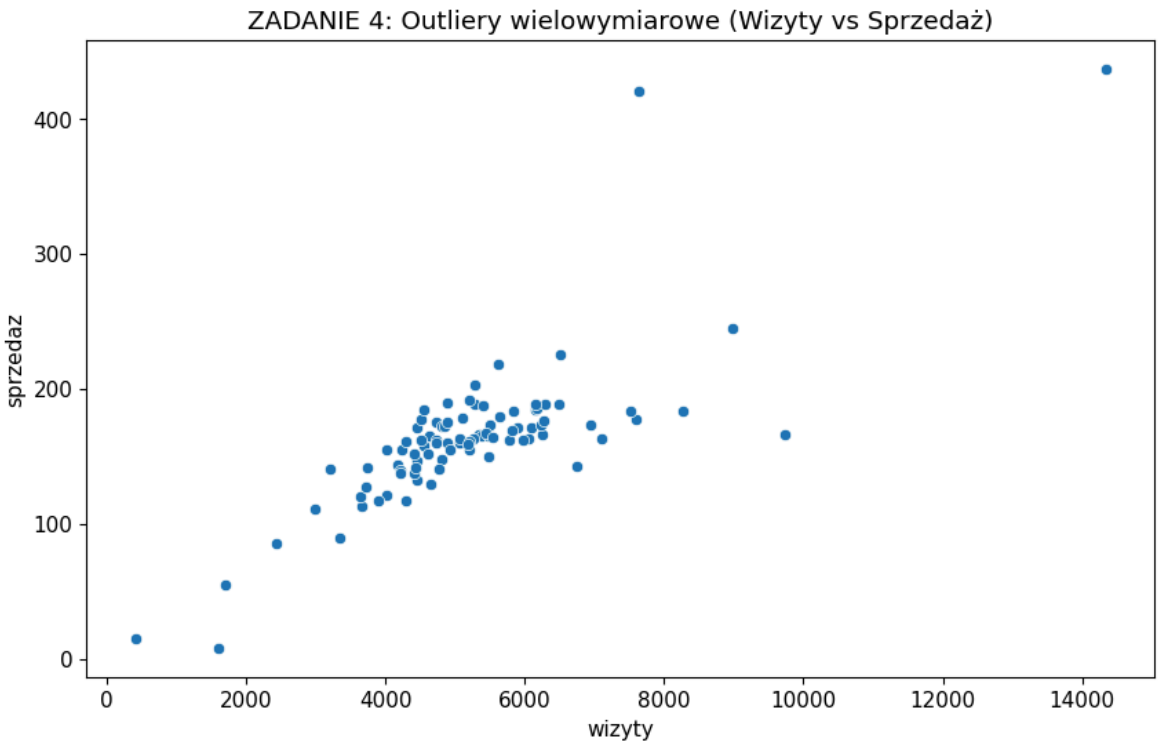


```
--- ZADANIE 5: ANALIZA ZWROTÓW ---
Dni z odsetkiem zwrotów powyżej 12%:
      data  sprzedaz  zwroty  procent_zwrotow
2024-01-18         8       1            12.50
2024-02-12       172      24            13.95
```